



Explicit Knowledge Graph Reasoning for Conversational Recommendation

一、摘要

1.1 研究背景

传统的推荐系统(RS)纯粹根据历史交互记录来估算用户对项目的偏好，因此无法捕捉细粒度但动态的用户兴趣，用户只能被动地接受推荐。最近出现的对话式推荐系统（CRSs）解决了这些局限性，它使推荐系统能够与用户互动，通过一连串的说明性问题获得用户当前的偏好

1.2 研究目的

尽管会话推荐系统取得了一些进展，但现有的解决方案在以下两个方面还远远不能令人满意：

- （1）当前的 CRS 通常要求每个用户在获得最终推荐之前回答大量的澄清问题，这损害了用户体验；
- （2）明确提及的属性和项目的学习表示之间存在语义差距。

1.3 解决方案

针对 1.2 提出的问题，作者引入了知识图谱（KG）作为理解和推理用户偏好的辅助信息，并提出了一种新的 CRS 框架，即知识增强对话推理（KECR）系统。由于用户可以通过属性和项目两个层面的表达来反映自己的偏好，KECR通过在KG中嵌入结构化知识，缩小了两个层面之间的语义差距。同时，KECR 利用 KG 内部的连通性对用户需求进行显式推理，使模型不再依赖于用户对澄清问题的反馈。KECR 可以找到一个突出的推理链，使推荐可解释、更合理，并使对话过程更流畅，从而带来更好的用户体验和对话推荐的准确性。

二、相关工作

2.1 知识图谱推理(Knowledge Graph Reasoning)

前期研究工作主要集中在对知识图谱进行多跳推理，以支持问题解答任务通过实体图或概念网来增强查询的语义表示，然后将其输入数据库，以促进基于相似性的检索。由于项目预测性能优越，一些推荐系统利用**KG嵌入技术**在推荐过程中改进项目嵌入，但是这种方法存在弊端，无法明确利用图中的连接信息，进而导致**可解释性的损失**；为了解决这个问题，人们提出了几种**基于路径的方法**。基于路径的方法旨在利用知识图谱中实体之间的联系，探索用户与推荐项目之间的突出路径[13, 56]。然而，这些方法缺乏获取用户需求的交互式方法，而且其推理过程仅限于预定义的元路径，无法根据用户的新输入进行动态改进 [42]。因此，它们的性能在很大程度上依赖于元路径工程的附加领域知识，而这是相当耗费人力的。

通过前人的研究，在知识图谱（KG）上执行**显式推理**已被证明是检索用户所需项目或答案的有效解决方案。

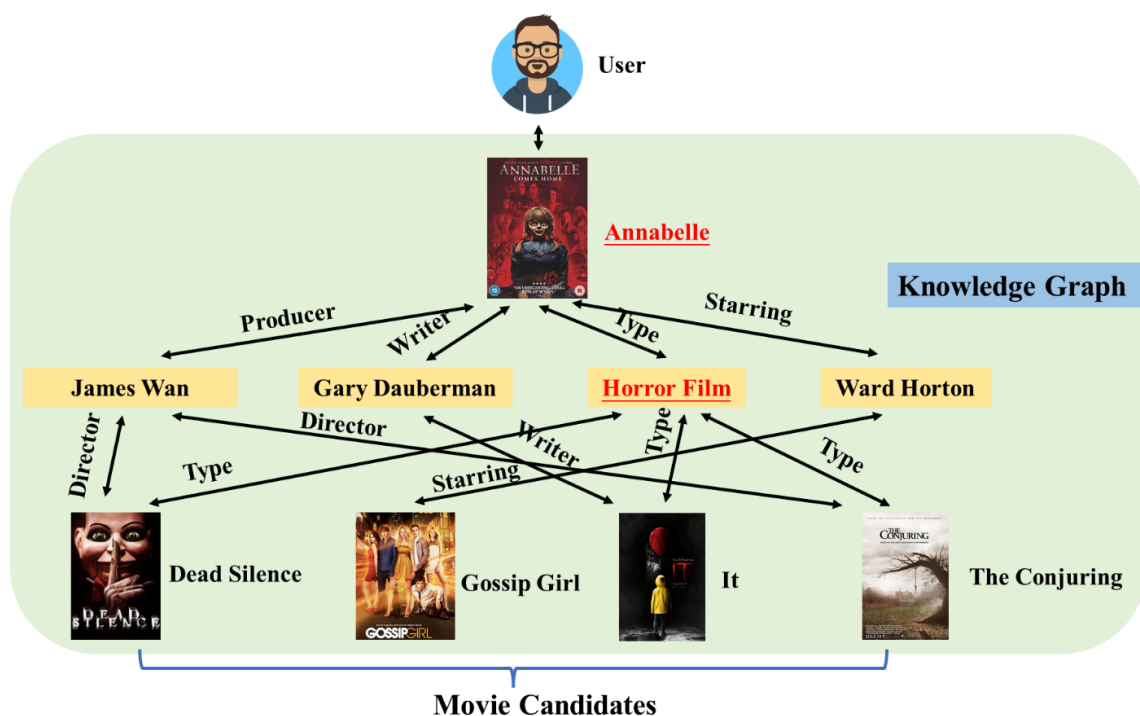


Fig. 1. An illustration of connection information inside the KG in the movie domain. The solid lines between entities represent their relations, while the underlined entity marked in red represents what the user mentioned during the conversation.

2.2 对话推荐(Conversational Recommendation)

CRS 已成为连接用户与系统之间互动的一种极具吸引力的方法，可通过可解释的准确推荐满足用户的实时需求。这一新兴研究课题源于面向任务的对话系统，该系统在多轮对话中帮助用户完成与推荐相关的任务。CRS 的传统设计遵循 SAUA 方式，即由 DC 针对预先定义的属性提出一系列说明性问题，以收集用户的明确偏好，并使用基于检索/协作过滤（CF）的推荐方法 [14]推导出个性化推荐。这类方法的主要局限性在于，现实世界的应用场景包含大量可用于提出澄清问题的候选属性。因此，用户在获得最终推荐之前可能需要回答许多澄清问题，这极大地损害了用户体验。此外，这些方法中的对话行为和内容也受到严格限制。用户和 CRS 只能就用户对一组固定属性的偏好进行交互，CRS 直接给出推荐而不作任何解释。这就导致了语篇理解中的语义空白，尤其是当用户同时反映其对项目和属性的偏好时。

最近的一些方法采用知识图谱（KG）来丰富会话信息，以弥补理解过程中的语义空白。例如，利用项目属性图将分层信息与推荐和对话生成过程有效地结合起来。正如第 1 节中所讨论的，大多数现有的相关工作都没有充分利用知识图谱的优势（例如，学习从知识图谱中检索到的子图的隐式表示）。作者认为，知识图谱的连接性信息是理解用户偏好的关键信息。对知识图谱进行显式推理可以更好地发挥 CRS 的优势。为此，作者通过在知识图谱上明确推理用户偏好，设计了一种新颖的会话推荐系统。因此，作者的模型能够高效、精确地学习用户偏好，并为生成回复提供合理的指导。

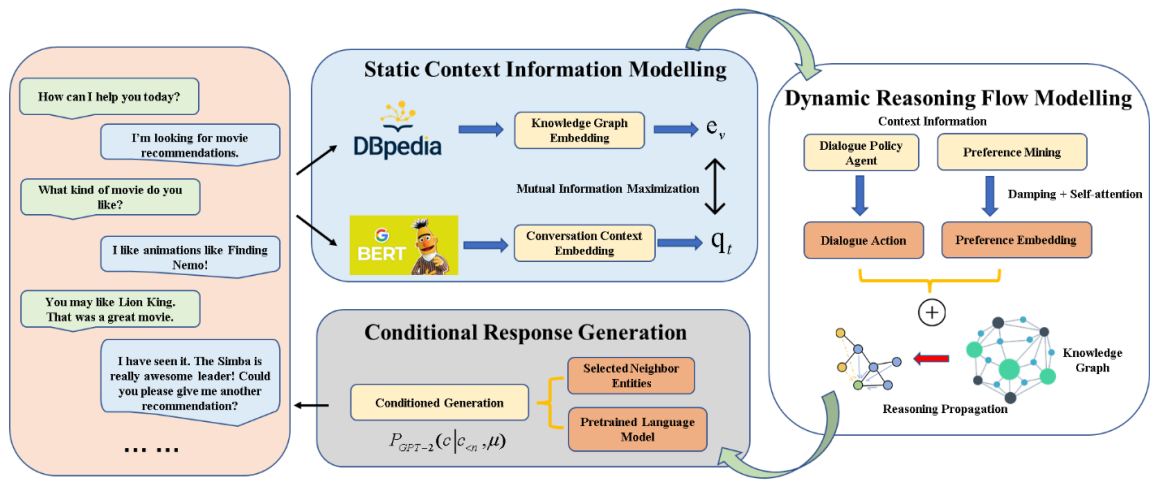


Fig. 2. The overall workflow of KECR. KECR is composed by three key components: Static Context Information Modelling, Dynamic Reasoning Flow Modelling and Conditional Response Generation.

2.3 静态语境信息建模(Static Context Information Modelling)

提出问题: 用户偏好的多样化表达(即项目级和属性级表达)使得理解用户话语中的潜在兴趣变得

困难，从而阻碍了 CRS 推导出准确的建议和合适的对话回应

解决方案:

① 引入了一个KG来丰富用户表达的语义，从而挖掘出用户在项目和属性层面的偏好之间的关联

② 采用预先训练好的语言模型来学习对话语境的语义表征。

•路径抽取与选择

论文在异构图上抽取用户物品对之间的多跳路径，用于获取用户的潜在兴趣的表示。然而考虑用户物品对之间的所有路径会涉及不相关的路径，导致错误传播问题。虽然定义元路径可以缓解错误传播的问题，但设计正确的元路径需要对特定领域的知识有深入的了解。为了解决错误传播和知识依赖问题，论文对用户物品对之间的不相关路径进行了修剪。对于用户物品对 (u, v)，论文找到u和v之间的路径集合。由于用户物品对之间的路径数量随着路径跳数呈指数增长，因此论文在提取路径时对跳数进行限制。

$$P(i_{k-1}, r_{k-1}, i_k) = \frac{\exp(f(e_i^{k-1}, e_r^{k-1}, e_i^k))}{\sum_{(i'_{k-1}, r'_{k-1}, i'') \in T_{k-1,k}} \exp(f(e_{i'}^{k-1}, e_{r'}^{k-1}, e_{i''}^k))},$$

考虑到在知识图谱中迭代每个用户物品对之间的所有路径效率低下，论文采用启发式的路径搜索算法进行路径抽取和选择。具体地，作者设计了一种基于特征转换的方法来为三元组打分，并利用核采样在用户物品对之间的路径中自适应地选择三元组，作者使用 $T_{k-1,k}$ 表示路径搜索中的第k-1跳和第k跳中的节点集合。对于节点集合 $T_{k-1,k}$ 中的节点 $(i'_{k-1}, r'_{k-1}, i'')$ ，作者在图中搜索它的邻居作为节点 i'' 的下一跳节点，对于邻居节点 i'' ，通过知识图谱表示方法计算对应三元组 $(i'_{k-1}, r'_{k-1}, i'')$ 的分数，其中 $(i'_{k-1}, r'_{k-1}, i'')$ 是第k-1和k跳之间的三元组。在论文中，三元组的分数通过TransH计算得出。

在计算了三元组的得分后，作者采用核采样在每个用户物品对之间的路径中自适应地选择三元组，TransH和核采样被用于进行路径排序和选择，滤低质量路径，进而解决路径上的错误传播问题。核采样旨在自适应地对候选概率分布的 top-p部分进行采样，作者的目标是降低低质量路径的分数并对其进行过滤。三元组内的语义关联（即置信度）越高，三元组的得分越高，那么路径被选中的概率越大，也就是说，得分较高的三元组对路径选择的贡献更大。

在每一跳，三元组从累积概率超过阈值的最小可能的三元组中选择，其中累积概率是通过对三元组的概率分数求和来计算的，采样的三元组的数量可以根据概率分布动态增加或减少，为了进行核采样，三元组分数被归一化用来计算三元组的概率。

其中 $s_{i'_{k-1}, r'_{k-1}, i''}$ 是 $(i'_{k-1}, r'_{k-1}, i'')$ 的分数，由TransH计算得出。给定第 k-1跳和第 k跳之间三元组的概率分布，被选择的三元组 $(i'_{k-1}, r'_{k-1}, i'')$ 被定义为满足以下条件的最小集合：

其中 p 是概率阈值。然后选择 中的三元组作为推理路径中的推理三元组，在每一跳，以与上述相同的方式选择三元组，最后形成推理路径集合 来反映用户 u 的潜在兴趣，减轻错误传播的影响。

•路径编码

虽然 已经包含了 u 和 v 之间的路径信息，但是这些路径主要是针对物品 v 的，不能反映用户 u 的其他兴趣，为了挖掘用户的更多兴趣，作者将用户的历史交互与选择路径的进行结合来捕获选择的路径和用户历史交互之间的相互影响。

KR-GCN 利用LSTM和注意力机制对选择的推理路径进行编码，该模块将图编码模块和路径抽取与选择模块的输出作为输入，图编码模块提供节点表示，路径提取和选择模块提供路径信息。由于路径中不同节点之间存在多跳关系信息和顺序依赖关系，因此该模块旨在捕获多跳关系信息并对每条路径内的顺序依赖关系进行编码。对于路径序列：

$$h_t = \text{LSTM}(h_{t-1}, e_i)$$

$$\alpha_{h_t} = \frac{\exp(\text{ReLU}(wh_t + b))}{\sum_{t'=1}^n \exp(\text{ReLU}(wh_{t'} + b'))}$$

$$P_{uv}[j] = \sum_{t=1}^n \alpha_{h_t} \cdot h_t$$

其中 是用户 u 和物品 v 之间选择的路径 的表示， α 表示节点 对路径 的重要性，用户 u 和物品 v 之间的多跳推理路径（或潜在关系） 由一组向量 表示，这些路径表示可以反映 u 的潜在兴趣传播。

•偏好预测

在推荐中，不同的路径通常对预测用户偏好的贡献不同，为了区分每个用户物品对之间不同路径对推理的不同贡献，KR-GCN采用了路径级的自注意力机制，学习每条路径上的路径权重，然后具有不同权重的多跳路径被聚合以表示用户的偏好。

$$p_{uv} = \text{maxpool}(P_{uv})$$

$$\hat{y}_{uv} = \sigma (MLP (p_{uv}))$$

其中 \mathcal{P}_{uv} 是路径集合 通过self-attention机制和max-pool操作的表示, 最终的预测得分 为用户u与物品v的交互概率, 即用户偏好预测得分